



87/100

**Ayoub Echchahed
(111 274 558)**

**Théorie de l'information
GEL-7062**

**Devoir 2
Résolution de Problèmes**

**Travail présenté à
Mr. Jean-Yves Chouinard**

**Faculté des sciences et de génie
Université Laval
Hiver 2022**


• **Problème 1 : Codage de source sans perte** 15/20

Problème 4.1 : Une source d'information discrète X génère des symboles avec la distribution d'entrée suivante : $p(x_1) = 0.37$, $p(x_2) = 0.28$, $p(x_3) = 0.18$, $p(x_4) = 0.12$, $p(x_5) = 0.05$.

- Donnez l'entropie de la source $H(X)$ en *shannons* (ou bits).
- Construisez un code de Huffman binaire pour cette source, écrivez les mots de code et leur longueur respective. Quelle est la longueur moyenne des mots de code ?
- Construisez un *code de Shannon-Fano* binaire, où $l_k = \lceil -\log_b p(x_k) \rceil$, pour cette source et donnez encore une fois les mots de code, leur longueur respective et la longueur moyenne des mots de code.
- Considérons maintenant des codes de Huffman and Shannon-Fano M -aires pour la même source d'information.
 - Déterminez l'entropie de la source $H(X)$ en unités M -aires.
 - Quel est le plus petit entier M tel que la longueur moyenne des mots de code du code Shannon-Fano M -aire sera la même que pour le code Huffman M -aire ? Expliquez et justifiez clairement votre réponse.

a) $H(X) = -\sum p(x_k) \log_2 p(x_k)$
 $= -[(0.37) \log_2 (0.37) + (0.28) \log_2 (0.28) + (0.18) \log_2 (0.18) + (0.12) \log_2 (0.12) + (0.05) \log_2 (0.05)]$
 $= -[(-0.5307) + (-0.5142) + (-0.4453) + (-0.3671) + (-0.2161)]$
 $= \mathbf{2.07 \text{ Sh}}$ 5/5

b)



Symbole x_k	Probabilité $p(x_k)$	Mot-code c_k	Longueur l_k
x_1	0.37	1	1
x_2	0.28	01	2
x_3	0.18	000	3
x_4	0.12	0010	4
x_5	0.05	0011	4

- Longueur moyenne :

$L = \sum p(x_k) l_k$
 $= (0.37) (1) + (0.28) (2) + (0.18) (3) + (0.12) (4) + (0.05) (4)$
 $= \mathbf{2.15 \text{ bits / symbole de source}}$ 5/5

c) - Using the binary expansion of the cumulative probabilities

Symbole x_k	Probabilité $p(x_k)$	Probabilités cumulées	Probabilités cumulées (binaire)	Longueur l_k $= \lceil -\log_2 p(x_k) \rceil$	Mot-code c_k
x1	0.37	0.00	0.00000	2	00
x2	0.28	0.37	0.010111	2	01
x3	0.18	0.65	0.101001	3	101
x4	0.12	0.83	0.110101	4	1101
x5	0.05	0.95	0.111100	5	11110

- Longueur moyenne :

$$\begin{aligned}
 L &= \sum p(x_k) l_k \\
 &= (0.37)(2) + (0.28)(2) + (0.18)(3) + (0.12)(4) + (0.05)(5) \\
 &= \mathbf{2.57 \text{ bits / symbole de source}}
 \end{aligned}$$

5/5

d)

i) Entropie de la source

(Calculer entropie pour base 3, base 4, base 5...)

$$\begin{aligned}
 H(X) &= -\sum p(x_k) \log_3 p(x_k) \\
 &= -[(0.37) \log_3 (0.37) + (0.28) \log_3 (0.28) + (0.18) \log_3 (0.18) + (0.12) \log_3 (0.12) + (0.05) \log_3 (0.05)] \\
 &= \mathbf{1.3082}
 \end{aligned}$$

$$\begin{aligned}
 H(X) &= -\sum p(x_k) \log_4 p(x_k) \\
 &= -[(0.37) \log_4 (0.37) + (0.28) \log_4 (0.28) + (0.18) \log_4 (0.18) + (0.12) \log_4 (0.12) + (0.05) \log_4 (0.05)] \\
 &= \mathbf{1.0367}
 \end{aligned}$$

$$\begin{aligned}
 H(X) &= -\sum p(x_k) \log_5 p(x_k) \\
 &= -[(0.37) \log_5 (0.37) + (0.28) \log_5 (0.28) + (0.18) \log_5 (0.18) + (0.12) \log_5 (0.12) + (0.05) \log_5 (0.05)] \\
 &= \mathbf{0.893}
 \end{aligned}$$

ii) Plus petit entier M où $L(\text{Huffman}) = L(\text{Shannon-Fano})$


0/5 M=20

• **Problème 2: Source d'information markovienne**

16/20

Problème 4.5 : Soit X une source d'information binaire avec mémoire, stationnaire et markovienne. Sa matrice de probabilité de transition est donnée par :

$$\mathbf{P} = \begin{bmatrix} p\left(x_1^{(n+1)} \middle| x_1^{(n)}\right) & p\left(x_2^{(n+1)} \middle| x_1^{(n)}\right) \\ p\left(x_1^{(n+1)} \middle| x_2^{(n)}\right) & p\left(x_2^{(n+1)} \middle| x_2^{(n)}\right) \end{bmatrix} = \begin{bmatrix} 0.7 & 0.3 \\ 0.9 & 0.1 \end{bmatrix}$$



- Déterminez les probabilités des symboles x_1 et x_2 .
- Calculez les entropies conditionnelles $H(X|x_1)$ et $H(X|x_2)$.
- Donnez l'entropie $H_{\text{mémoire}}(X)$ de ce canal avec mémoire.
- Maintenant supposez que le canal est sans mémoire mais avec les mêmes probabilités $p(x_1)$ et $p(x_2)$ trouvées en (a). Quelle est l'entropie $H(X)$ de ce canal sans mémoire ?
- Comparez les valeurs d'entropie avec et sans mémoire, $H_{\text{mémoire}}(X)$ et $H(X)$ et expliquez les résultats obtenus.

$$\mathbf{p} = \left\{ p(x_1) = \frac{\beta}{\alpha + \beta}, p(x_2) = \frac{\alpha}{\alpha + \beta} \right\}$$

a) 4/4

$$p(x_1) = 0.9 / (0.3 + 0.9) = 0.75$$

$$p(x_2) = 0.3 / (0.3 + 0.9) = 0.25$$

L'entropie $H(X_n)$ au temps discret n :

$$\begin{aligned} H(X_n) &= -[p(x_1) \log_b p(x_1) + p(x_2) \log_b p(x_2)] \\ H(X_n) &= -\left[\left(\frac{\beta}{\alpha + \beta} \right) \log_b \left(\frac{\beta}{\alpha + \beta} \right) + \left(\frac{\alpha}{\alpha + \beta} \right) \log_b \left(\frac{\alpha}{\alpha + \beta} \right) \right] \end{aligned}$$

Le taux d'entropie $H_R(X)$ est donc :

$$\begin{aligned} H_R(X) &= H(X_2 | X_1) = - \sum_{k=1}^2 \sum_{j=1}^2 p(x_k) p(x_j | x_k) \log_b p(x_j | x_k) \\ H_R(X) &= - \sum_{k=1}^2 p(x_k) \sum_{j=1}^2 p(x_j | x_k) \log_b p(x_j | x_k) \\ H_R(X) &= - \left\{ \left(\frac{\beta}{\alpha + \beta} \right) [(1 - \alpha) \log_b (1 - \alpha) + \alpha \log_b \alpha] \right. \\ &\quad \left. + \left(\frac{\alpha}{\alpha + \beta} \right) [\beta \log_b \beta + (1 - \beta) \log_b (1 - \beta)] \right\} \end{aligned}$$

$$\mathbf{P} = \begin{bmatrix} p\left(x_1^{(n+1)} \middle| x_1^{(n)}\right) & p\left(x_2^{(n+1)} \middle| x_1^{(n)}\right) \\ p\left(x_1^{(n+1)} \middle| x_2^{(n)}\right) & p\left(x_2^{(n+1)} \middle| x_2^{(n)}\right) \end{bmatrix} = \begin{bmatrix} (1 - \alpha) & \alpha \\ \beta & (1 - \beta) \end{bmatrix}$$

b)

4/4

$$\begin{aligned}
 H(X | x_1) &= - \sum p(x_k, y_j) \log_b p(x_k | y_j) \\
 &= - [0.7 \log_2 (0.7) + 0.3 \log_2 (0.3)] \\
 &= 0.8813 \text{ Sh}
 \end{aligned}$$

$$p(x_1) = 1$$

$$\begin{aligned}
 H(\tilde{Y} | x = x_1) &= -[p(y = y_1 | x = x_1) \log p(y = y_1 | x = x_1) \\
 &\quad + p(y = y_2 | x = x_1) \log p(y = y_2 | x = x_1)]
 \end{aligned}$$

$$\begin{aligned}
 H(X | x_2) &= - \sum p(x_k, y_j) \log_b p(x_k | y_j) \\
 &= - [0.9 \log_2 (0.9) + 0.1 \log_2 (0.1)] \\
 &= 0.469 \text{ Sh}
 \end{aligned}$$

$$p(x_2) = 1$$

c)

$$\begin{aligned}
 H_R(X) &= - \{ (\beta / (\alpha + \beta)) [(1 - \alpha) \log_b (1 - \alpha) + \alpha \log_b \alpha] + ((\alpha / (\alpha + \beta)) [\beta \log_b \beta + (1 - \beta) \log_b (1 - \beta)]) \} \\
 &= - \{ (0.9 / (0.3 + 0.9)) [(0.7) \log_b (0.7) + 0.3 \log_b 0.3] + ((0.3 / (0.3 + 0.9)) [0.9 \log_b 0.9 + (0.1) \log_b (0.1)] \} \\
 &= - \{ (0.75) [-0.88129] + (0.25) [-0.468996] \} \\
 &= 0.5437 \text{ Sh}
 \end{aligned}$$

0/4

d)

$$\begin{aligned}
 p(x_1) &= 0.75 \\
 p(x_2) &= 0.25
 \end{aligned}$$

$$\begin{aligned}
 H(X) &= - [p(x_1) \log_2 p(x_1) + (p(x_2)) \log_2 (p(x_2))] \\
 &= - [0.75 \log_2 0.75 + (0.25 \log_2 0.25)] \\
 &= 0.8113 \text{ Sh}
 \end{aligned}$$

4/4

e)

4/4

- 0.5437 Sh (avec mémoire)
- 0.8113 Sh (sans mémoire)

L'entropie avec mémoire est **moindre** que l'entropie sans mémoire puisque celle-ci se voit réduite en raison de l'information additionnelle disponible du passé, ce qui réduit donc l'incertitude du canal.

• **Problème 3 : Convexité de l'information mutuelle**

5/5

Problème 5.1 : L'information mutuelle $I(X; Y)$ est une fonction convexe (i.e. *fonction concave*) définie sur l'ensemble convexe des distributions des symboles d'entrée $\mathcal{S}_p = \{p\}$. Cependant, $I(X; Y)$ est une fonction convexe (i.e. *fonction convexe*) sur l'ensemble convexe des matrices de probabilités de transition d'un canal $\mathcal{S}_P = \{P\}$.

- Démontrez que l'ensemble convexe des matrices de probabilités de transition \mathcal{S}_P forme un ensemble convexe.
- Démontrez que sur cet ensemble convexe \mathcal{S}_P , l'information mutuelle est une fonction convexe.

a) Ensemble de toutes les distributions possibles \rightarrow Matrice de probabilités de transition $P = \mathcal{S}_p \rightarrow$ Paramètre α & β

$$P = \begin{bmatrix} p(x_1^{(n+1)} | x_1^{(n)}) & p(x_2^{(n+1)} | x_1^{(n)}) \\ p(x_1^{(n+1)} | x_2^{(n)}) & p(x_2^{(n+1)} | x_2^{(n)}) \end{bmatrix} = \begin{bmatrix} (1-\alpha) & \alpha \\ \beta & (1-\beta) \end{bmatrix}$$

Définition (Fonction convexe) : Un ensemble de points S est convexe si, pour toute paire de points $x_1 \in S$ et $x_2 \in S$, tout point x reliant ces deux points x_1 et x_2 est lui aussi compris dans l'ensemble de points S .

- Deux conditions:

- $0 \leq p(x_k) \leq 1$, pour $k = 1, 2, 3, 4$
- $\sum p(x_k) = 1$

1) Soient x_1 et x_2 , deux points dans un espace à 2 dimensions.

Tout point x sur la droite reliant les points x_1 et x_2 peut s'exprimer par :

$$x = \lambda x_1 + (1 - \lambda) x_2, \text{ où } \lambda \in [0, 1]$$

$$\lambda = 1 \rightarrow x = x_1$$

$$\lambda = 0 \rightarrow x = x_2$$

$0 \leq \lambda \leq 1$, le point x est situé sur la droite reliant x_1 et x_2 .

- Sachant que dû aux lois des probabilités :

$$0 \leq (\alpha) \leq 1$$

$$0 \leq (\beta) \leq 1,$$

$$\text{alors : } p(x_k) = \lambda p_1(x_k) + (1 - \lambda) p_2(x_k) \geq 0, \text{ pour } k = 1, 2.$$

2) Since the total of transition probability from a state i to all other states must be 1

$$-\sum \beta + (1 - \beta) = 1$$

$$-\sum \alpha + (1 - \alpha) = 1$$


$$\text{Donc tout point } p = \lambda p_1 + (1 - \lambda) p_2,$$

Défini avec deux distributions:

$$P_1 = [\beta_1, \alpha_1] \text{ ou } \{p_1(y | x)\}$$

$$P_2 = [\beta_2, \alpha_2] \text{ ou } \{p_2(y | x)\}$$


est lui-même une distribution valide, et ce pour tout choix de paires de distributions p_1 et p_2 . **Donc l'ensemble \mathcal{S}_p de toutes les distributions à dimensions (ici $N = 2$) forment un ensemble convexe.**



b) Démontrez que sur cet ensemble convexe S_P , l'information mutuelle est une fonction convexe \cup .

- **Définition (Fonction convexe)** : Une fonction réelle $f(x)$, définie sur un ensemble convexe S est dite convexe (convexe vers le haut ou convexe \cup) si, pour tout point x sur la droite reliant la paire de points x_1 et x_2 , i.e. $x = \lambda x_1 + (1 - \lambda) x_2$, ($\lambda \in [0, 1]$) :

$$f(x) \leq \lambda f(x_1) + (1 - \lambda) f(x_2)$$




$$I_M(X, Y) = \sum_i \sum_j p(x_i, y_j) \log_2 \frac{p(x_i, y_j)}{p(x_i)p(y_j)}$$

$$I(X; Y) = f(p, P) = I(p; P)$$

Fixons la distribution de symbole p et faisons varier les probabilités de transition P

Donc assumons 2 distributions différentes de la matrice de probabilités de transition P :

- P_1 avec $= \{p_1(y | x)\}$
- P_2 avec $= \{p_2(y | x)\}$



La distribution P , entre les distributions P_1 et P_2 dans l'ensemble convexe S_P est donnée par

$$P = \lambda P_1 + (1 - \lambda) P_2$$

$$P(y_j | x_k) = \lambda P_1(y_j | x_k) + (1 - \lambda) P_2(y_j | x_k) \text{ pour un } \lambda \in [0, 1]$$

Soit I_1, I_2 l'information mutuelle moyenne de P, P_1 , et P_2 respectivement. Il est donc nécessaire de prouver que: $\lambda I_1 + (1 - \lambda) I_2 \geq I$

Donc si l'information $I(X; Y) = I(p; P)$ est une fonction convexe de la distribution de l'ensemble des paramètres α & β , alors :

$$I(X; Y) \leq \lambda I(p(x), p_1(y|x)) + (1 - \lambda) I(p(x), p_2(y|x))$$

Si c'est le cas, alors :

$$\rightarrow \lambda I(p(x), p_1(y|x)) + (1 - \lambda) I(p(x), p_2(y|x)) - I(X; Y) \geq 0$$

$$\begin{aligned} \rightarrow \lambda I(p(x), p_1(y|x)) + (1 - \lambda) I(p(x), p_2(y|x)) - I(X; Y) = \\ \lambda \sum p(x_k) p_1(y_j | x_k) \log_b \left(\frac{p_1(y_j | x_k)}{p(y_j)} \right) + (1 - \lambda) \sum p(x_k) p_2(y_j | x_k) \log_b \left(\frac{p_2(y_j | x_k)}{p(y_j)} \right) - \\ \sum p(x_k) p(y_j | x_k) \log_b \left(\frac{p(y_j | x_k)}{p(y_j)} \right) \end{aligned}$$

...
(Même démarche que p.90/p.91 des notes)

De ce fait, l'information mutuelle moyenne $I(X; Y)$ est une fonction convexe (\cup) sur l'ensemble convexe S_P de toutes les matrices de probabilité de transition possibles $\{P\}$

- **Autre méthode pour prouver convexité de la fonction $I(X; Y)$?**

J'ai remarqué à plusieurs reprises l'utilisation d'une seconde méthode beaucoup plus courte que celle que vous avez utilisée afin de prouver la convexité de l'information sur l'ensemble convexe S_p de toutes les matrices de probabilité de transition possibles. Elle consiste à introduire une variable aléatoire Z où $I(X; Z) = 0 \dots$ Voilà un exemple:

1 Convexity/Concavity of Mutual Information

In the previous lecture, we saw that mutual information is concave in p . To be more precise, let (X, Y) have a joint probability distribution $p(x, y) = p(x)p(y|x)$. Write $\alpha = \alpha(x) = p(x)$ and $\pi = \pi(x, y) = p(y|x)$. Then the pair (α, π) specifies the distribution $p(x, y)$.

Lemma 1 (Mutual information is concave in p).

Let I_1 be $I(X; Y)$ where $(X, Y) \sim (\alpha_1, \pi)$,

let I_2 be $I(X; Y)$ where $(X, Y) \sim (\alpha_2, \pi)$,

let I be $I(X; Y)$ where $(X, Y) \sim (\lambda\alpha_1 + (1 - \lambda)\alpha_2, \pi)$, for some $0 \leq \lambda \leq 1$.

then $I \geq \lambda I_1 + (1 - \lambda)I_2$.

Now, we prove that mutual information is convex in $p(y|x)$. More formally, we have the following. Let (X, Y) have a joint probability distribution $p(x, y) = p(x)p(y|x)$. Write $\alpha = \alpha(x) = p(x)$ and $\pi = \pi(x, y) = p(y|x)$. Then the pair (α, π) specifies the distribution $p(x, y)$.

— **Lemma 2** (Mutual information is convex in π). Let I_1 be $I(X; Y)$ where $(X, Y) \sim (\alpha, \pi_1)$,

let I_2 be $I(X; Y)$ where $(X, Y) \sim (\alpha, \pi_2)$,

let I be $I(X; Y)$ where $(X, Y) \sim (\alpha, \lambda\pi_1 + (1 - \lambda)\pi_2)$, for some $0 \leq \lambda \leq 1$.

then $I \leq \lambda I_1 + (1 - \lambda)I_2$.

— **Proof** Let us draw X first according to α . Let S be a B_λ random variable such that S is 1 with probability λ and 0 with probability $1 - \lambda$. If $S = 1$ we select Y using π_1 , and otherwise we select Y using π_2 . Note that $I(X; Y) = I$.

$$I(SY; X) = I(Y; X) + I(S; X|Y) \geq I(Y; X) = I$$

Also, we have

$$\begin{aligned} I(SY; X) &= I(S; X) + I(Y; X|S) \\ &= 0 + I(Y; X|S) \\ &= \lambda I(Y; X|S = 1) + (1 - \lambda)I(Y; X|S = 0) \\ &= \lambda I_1 + (1 - \lambda)I_2 \end{aligned}$$


Thus, we have $I \leq \lambda I_1 + (1 - \lambda)I_2$.

• Problème 4 : Séquences conjointement typique

20/20

Jointly typical sequences. As we did in Problem 3.13 for the typical set for a single random variable, we will calculate the jointly typical set for a pair of random variables connected by a binary symmetric

channel, and the probability of error for jointly typical decoding for such a channel.



We consider a binary symmetric channel with crossover probability 0.1. The input distribution that achieves capacity is the uniform distribution [i.e., $p(x) = (\frac{1}{2}, \frac{1}{2})$], which yields the joint distribution $p(x, y)$ for this channel is given by

$X \backslash Y$	0	1
0	0.45	0.05
1	0.05	0.45

The marginal distribution of Y is also $(\frac{1}{2}, \frac{1}{2})$.

- (a) Calculate $H(X)$, $H(Y)$, $H(X, Y)$, and $I(X; Y)$ for the joint distribution above.
- (b) Let X_1, X_2, \dots, X_n be drawn i.i.d. according to the Bernoulli($\frac{1}{2}$) distribution. Of the 2^n possible input sequences of length n , which of them are typical [i.e., member of $A_\epsilon^{(n)}(X)$ for $\epsilon = 0.2$]? Which are the typical sequences in $A_\epsilon^{(n)}(Y)$?
- (c) The jointly typical set $A_\epsilon^{(n)}(X, Y)$ is defined as the set of sequences that satisfy equations (7.35-7.37). The first two equations correspond to the conditions that x^n and y^n are in $A_\epsilon^{(n)}(X)$ and $A_\epsilon^{(n)}(Y)$, respectively. Consider the last condition, which can be rewritten to state that $-\frac{1}{n} \log p(x^n, y^n) \in (H(X, Y) - \epsilon, H(X, Y) + \epsilon)$. Let k be the number of places in which the sequence x^n differs from y^n (k is a function of the two sequences). Then we can write

$$p(x^n, y^n) = \prod_{i=1}^n p(x_i, y_i) \quad (7.156)$$

$$= (0.45)^{n-k} (0.05)^k \quad (7.157)$$

$$= \left(\frac{1}{2}\right)^n (1-p)^{n-k} p^k. \quad (7.158)$$

An alternative way of looking at this probability is to look at the binary symmetric channel as an additive channel $Y = X \oplus Z$, where Z is a binary random variable that is equal to 1 with probability p , and is independent of X . In this case,

$$p(x^n, y^n) = p(x^n) p(y^n | x^n) \quad (7.159)$$

$$= p(x^n) p(z^n | x^n) \quad (7.160)$$

$$= p(x^n) p(z^n) \quad (7.161)$$

$$= \left(\frac{1}{2}\right)^n (1-p)^{n-k} p^k. \quad (7.162)$$

Show that the condition that (x^n, y^n) being jointly typical is equivalent to the condition that x^n is typical and $z^n = y^n - x^n$ is typical.

- (d) We now calculate the size of $A_\epsilon^{(n)}(Z)$ for $n = 25$ and $\epsilon = 0.2$. As in Problem 3.13, here is a table of the probabilities and numbers of sequences with k ones:

k	$\binom{n}{k}$	$\binom{n}{k} p^k (1-p)^{n-k}$	$-\frac{1}{n} \log p(x^n)$
0	1	0.071790	0.152003
1	25	0.199416	0.278800
2	300	0.265888	0.405597
3	2300	0.226497	0.532394
4	12650	0.138415	0.659191
5	53130	0.064594	0.785988
6	177100	0.023924	0.912785
7	480700	0.007215	1.039582
8	1081575	0.001804	1.166379
9	2042975	0.000379	1.293176
10	3268760	0.000067	1.419973
11	4457400	0.000010	1.546770
12	5200300	0.000001	1.673567

[Sequences with more than 12 ones are omitted since their total probability is negligible (and they are not in the typical set).] What is the size of the set $A_\epsilon^{(n)}(Z)$?

a)

$$H(X) = 1 \text{ bit}$$

$$H(Y) = 1 \text{ bit}$$

5/5

$$\begin{aligned} H(X, Y) &= H(X) + H(Y | X) \\ &= 1 - [0.9 \log_2 0.9 - 0.1 \log_2 0.1] \\ &= 1.469 \text{ bits} \end{aligned}$$

$$\begin{aligned} I(X; Y) &= H(Y) - H(Y | X) \\ &= 0.531 \text{ bits} \end{aligned}$$

b) Of the 2^n possible input sequences of length n , which of them are typical [member of $A^{(n)} \in (X)$] for $\epsilon = 0.2$? Which are the typical sequences in $A^{(n)} \in (Y)$?

- If uniform distribution:

$$p = (1/2)^n$$

$$[-(1/n) \log_2 p(x)] = 1$$

$$H(X) = 1$$

$$1 - 1 = 0$$

$$0 \leq \delta$$

— l'ensemble $\mathcal{T}_X(\delta)$ des séquences typiques de longueur N :

$$\mathcal{T}_X(\delta) \triangleq \left\{ \mathbf{x} : \left| -\frac{1}{N} \log_2 p(\mathbf{x}) - H(X) \right| \leq \delta \right\}$$

5/5

→ Every sequence \mathbf{x}^n is typical $\in A^{(n)} \in (X)$

→ Every sequence \mathbf{y}^n is typical $\in A^{(n)} \in (Y)$

c) Show that the condition that $(\mathbf{x}^n, \mathbf{y}^n)$ being jointly typical is equivalent to the condition that \mathbf{x}^n is typical and $\mathbf{z}^n = \mathbf{y}^n - \mathbf{x}^n$ is typical.

- Conditions $(\mathbf{x}^n, \mathbf{y}^n)$ are jointly typical (image):

1 | 2 | 3

Every sequence \mathbf{x}^n and \mathbf{y}^n satisfies 1 & 2

Hence looking at condition 3

and replacing $p(\mathbf{x}^n, \mathbf{y}^n)$

We get:

5/5

$$\left| -\frac{1}{n} \log_2 \left(\left(\frac{1}{2} \right)^n p^k (1-p)^{n-k} \right) - H(X, Y) \right| < \epsilon$$

Which is similar to condition for typicality of $\mathbf{z}^n = \mathbf{y}^n \oplus \mathbf{x}^n$

d) What is the size of the set $A^{(n)} \in (Z)$?

$$n = 25$$

$$\epsilon = 0.2$$

$$H(Z) = 0.469$$

5/5

Typical set for Z : $-(1/n) \log_2 p(\mathbf{z}^n) \in (H(Z) - \epsilon, H(Z) + \epsilon)$

$$\in (0.269; 0.669)$$

-- Typical Z sequences → $k = 1, 2, 3, 4$

Total probability of set $A^{(n)} \in (Z) = 0.902 - 0.071$

$$= 0.830 \%$$

Size = $15276 - 1$

= 15 275 sequences

7.6 JOINTLY TYPICAL SEQUENCES

Roughly speaking, we decode a channel output \mathbf{Y}^n as the i th index if the codeword $\mathbf{X}^n(i)$ is "jointly typical" with the received signal \mathbf{Y}^n . We now define the important idea of joint typicality and find the probability of joint typicality when $\mathbf{X}^n(i)$ is the true cause of \mathbf{Y}^n and when it is not.

Definition The set $A^{(n)}$ of jointly typical sequences $\{(\mathbf{x}^n, \mathbf{y}^n)\}$ with respect to the distribution $p(x, y)$ is the set of n -sequences with empirical entropies ϵ -close to the true entropies:

$$A^{(n)} = \{(\mathbf{x}^n, \mathbf{y}^n) \in \mathcal{X}^n \times \mathcal{Y}^n : \left| -\frac{1}{n} \log p(\mathbf{x}^n) - H(X) \right| < \epsilon, \quad (7.35)$$

196 CHANNEL CAPACITY

$$2 \quad \left| -\frac{1}{n} \log p(\mathbf{y}^n) - H(Y) \right| < \epsilon, \quad (7.36)$$

$$3 \quad \left| -\frac{1}{n} \log p(\mathbf{x}^n, \mathbf{y}^n) - H(X, Y) \right| < \epsilon, \quad (7.37)$$

$$p(\mathbf{x}^n, \mathbf{y}^n) = \prod_{i=1}^n p(x_i, y_i) \quad (7.73)$$

$$= (0.45)^{n-k} (0.05)^k \quad (7.74)$$

$$= \left(\frac{1}{2} \right)^n (1-p)^{n-k} p^k \quad (7.75)$$

An alternative way at looking at this probability is to look at the binary symmetric channel as in additive channel $Y = X \oplus Z$, where Z is a binary random variable that is equal to 1 with probability p , and is independent of X . In this case,

$$p(\mathbf{x}^n, \mathbf{y}^n) = p(\mathbf{x}^n) p(\mathbf{y}^n | \mathbf{x}^n) \quad (7.76)$$

$$= p(\mathbf{x}^n) p(\mathbf{z}^n | \mathbf{x}^n) \quad (7.77)$$

$$= p(\mathbf{x}^n) p(\mathbf{z}^n) \quad (7.78)$$

$$= \left(\frac{1}{2} \right)^n (1-p)^{n-k} p^k \quad (7.79)$$

• **Problème 5 : Capacité d'un canal asymétrique**

15/15

Problème 6.5 : Pour ce problème, écrivez un programme pour calculer la capacité C de canaux asymétriques. Utilisez l'algorithme de Blahut-Arimoto vue en classe. Donnez le listing de votre programme. Note : vous pouvez vous référer entre autres à la section 5.4 du livre "Principles and Practice of Information Theory" de Richard E. Blahut ou à la section correspondante de livre "Elements of Information Theory" de Thomas M. Cover et Joy A. Thomas. Calculez la capacité des canaux de communication suivants :

- a) Déterminez la capacité C_1 du canal caractérisé par la matrice de probabilité de transition \mathbf{P}_1 et donnez la distribution des symboles de source \mathbf{p}_1^* correspondante.

$$\mathbf{P}_1 = \begin{pmatrix} 0.7 & 0.2 & 0.1 \\ 0.2 & 0.1 & 0.7 \end{pmatrix}$$

- b) Déterminez la capacité C_2 du canal caractérisé par la matrice de probabilité de transition \mathbf{P}_2 et donnez la distribution des symboles de source \mathbf{p}_2^* correspondante.

$$\mathbf{P}_2 = \begin{pmatrix} 0.4 & 0.2 & 0.4 & 0.0 & 0.0 \\ 0.0 & 0.4 & 0.2 & 0.4 & 0.0 \\ 0.2 & 0.2 & 0.2 & 0.2 & 0.2 \\ 0.4 & 0.0 & 0.0 & 0.4 & 0.2 \\ 0.2 & 0.4 & 0.0 & 0.0 & 0.4 \end{pmatrix}$$

- c) Déterminez la capacité C_3 du canal caractérisé par la matrice de probabilité de transition \mathbf{P}_3 et donnez la distribution des symboles de source \mathbf{p}_3^* correspondante.

$$\mathbf{P}_3 = \begin{pmatrix} 0.11 & 0.25 & 0.04 & 0.10 & 0.20 & 0.00 & 0.12 & 0.18 \\ 0.27 & 0.00 & 0.14 & 0.05 & 0.13 & 0.26 & 0.10 & 0.05 \\ 0.11 & 0.09 & 0.18 & 0.32 & 0.16 & 0.08 & 0.04 & 0.02 \\ 0.00 & 0.10 & 0.15 & 0.25 & 0.25 & 0.15 & 0.10 & 0.00 \\ 0.11 & 0.27 & 0.09 & 0.03 & 0.03 & 0.09 & 0.27 & 0.11 \\ 0.25 & 0.00 & 0.00 & 0.25 & 0.25 & 0.00 & 0.00 & 0.25 \\ 0.27 & 0.00 & 0.14 & 0.05 & 0.13 & 0.26 & 0.10 & 0.05 \\ 0.11 & 0.25 & 0.04 & 0.10 & 0.20 & 0.00 & 0.12 & 0.18 \end{pmatrix}$$

a)

$$C_1 = 0.2091$$

$$\text{Distribution } \mathbf{p}_1^* = [0.5255, 0.4744] \quad 5/5$$

b)

$$C_2 = 0.5293$$

$$\text{Distribution } \mathbf{p}_2^* = [0.2564, 0.2436, 3.42435657\text{e-}06, 0.2438, 0.2563] \quad 5/5$$

c)

5/5


$$C_3 = 0.4106$$

$$\text{Distribution } \mathbf{p}_3^* = [4.268\text{e-}09, 0.04525, 7.234\text{e-}08, 0.1926, 0.2792, 0.4529, 0.030038, 3.458\text{e-}09]$$

Problème 6 : Capacité de canaux symétriques en cascade

16/20


La figure ci-dessous montre deux canaux symétriques binaires en cascade.



- Écrivez l'expression de l'information mutuelle du canal $I(X;Y)$ en fonction de ϵ_1 .
- Écrivez l'expression de l'information mutuelle du canal $I(X;Z)$ en fonction de ϵ_1 de ϵ_2 .
- Donnez capacité du canal C_{XY} pour $\epsilon_1 = 0.1$.
- Donnez capacité du canal C_{XZ} pour $\epsilon_1 = 0.1$ et $\epsilon_2 = 0.2$.
- À l'aide d'un logiciel, tracez les courbes suivantes :
 - C_{XY} pour $0 \leq \epsilon_1 \leq 1$.
 - C_{XZ} pour $0 \leq \epsilon_1 \leq 1$ et $0 \leq \epsilon_2 \leq 1$ (graphique 3D). Expliquez les résultats obtenus.

a) Mutual information can be seen as X uncertainty less error sequence uncertainty

Because it is a symmetric channel \rightarrow input distribution p^* is an equiprobable source distribution: $p(x_1) = p(x_2) = 1/2$ **X**



$$H(X) = 1 \text{ Sh}$$

$$H(E) = - \sum p(y_j|x_k) \log_b p(y_j|x_k) \\ = - [(1-\epsilon) \log_b (1-\epsilon) + \epsilon \log_b \epsilon]$$

$$I(X;Y) = H(X) - H(E) \\ = 1 + [(1-\epsilon) \log_b (1-\epsilon) + \epsilon \log_b \epsilon]$$

E as row of the transition matrix

0/4

b) The channel has the transition matrix:

Again, because it is a symmetric channel \rightarrow input distribution p^* is an equiprobable source distribution:

$$p(x_1) = p(x_2) = 1/2 \quad \text{X}$$

$$H(X) = 1 \text{ Sh}$$

$$H(E) = - \sum p(y_j | x_k) \log_b p(y_j | x_k) \\ = - [(1 - \epsilon) \log_b (1 - \epsilon) + \epsilon \log_b \epsilon]$$

E as row of the transition matrix

$$P = \begin{bmatrix} 1-\epsilon_1 & \epsilon_1 \\ \epsilon_1 & 1-\epsilon_1 \end{bmatrix} \begin{bmatrix} 1-\epsilon_2 & \epsilon_2 \\ \epsilon_2 & 1-\epsilon_2 \end{bmatrix} \\ = \begin{bmatrix} (1-\epsilon_1)(1-\epsilon_2) + \epsilon_1 \epsilon_2 & (1-\epsilon_1)\epsilon_2 + \epsilon_1(1-\epsilon_2) \\ \epsilon_1(1-\epsilon_2) + (1-\epsilon_1)\epsilon_2 & \epsilon_1 \epsilon_2 + (1-\epsilon_1)(1-\epsilon_2) \end{bmatrix}$$

The two cascaded BSC channels can be viewed as a single BSC channel with an overall loss parameter $\epsilon = \epsilon_1(1 - \epsilon_2) + \epsilon_2(1 - \epsilon_1)$ 4/4

$$I(X; Z) = H(X) - H(E) \\ = 1 + [(1 - \epsilon) \log_b (1 - \epsilon) + \epsilon \log_b \epsilon] \\ = 1 + [(1 - [\epsilon_1(1 - \epsilon_2) + \epsilon_2(1 - \epsilon_1)]) \log_b (1 - [\epsilon_1(1 - \epsilon_2) + \epsilon_2(1 - \epsilon_1)]) + [\epsilon_1(1 - \epsilon_2) + \epsilon_2(1 - \epsilon_1)] \log_b [\epsilon_1(1 - \epsilon_2) + \epsilon_2(1 - \epsilon_1)]]$$

c) $\epsilon_1 = 0.1$

$$C = \text{Max } I(X; Y) \\ = 1 + [(1 - 0.1) \log_2 (1 - 0.1) + 0.1 \log_2 0.1] \\ = 1 + [-0.1368 - 0.33219] \\ = 0.5310 \text{ Sh} \quad 4/4$$

d) $\epsilon_1 = 0.1$ & $\epsilon_2 = 0.2$

The two cascaded BSC channels can be viewed as a single BSC channel with an overall loss parameter ϵ :

$$\epsilon = \epsilon_1(1 - \epsilon_2) + \epsilon_2(1 - \epsilon_1) \\ \epsilon = 0.1(1 - 0.2) + 0.2(1 - 0.1) \\ \epsilon = 0.26$$

$$C = \text{Max } I(X; Y) \\ = 1 + [(1 - \epsilon) \log_b (1 - \epsilon) + \epsilon \log_b \epsilon]$$

$$\begin{aligned}
&= 1 + [(1 - 0.26) \log_b (1 - 0.26) + 0.26 \log_b 0.26] \\
&= 1 + [(0.74) \log_2 (0.74) + 0.26 \log_2 0.26] \\
&= 1 + [-0.32146 - 0.5053] \\
&= 0.1732 \text{ Sh}
\end{aligned}$$

4/4


e)

4/4

- C_{XY} pour $0 \leq \epsilon_1 \leq 1$

$$0 \leq \epsilon \leq 1$$

$$C = 1 + [(1 - \epsilon) \log_b (1 - \epsilon) + \epsilon \log_b \epsilon]$$




- C_{XZ} pour $0 \leq \epsilon_1 \leq 1$ & $0 \leq \epsilon_2 \leq 1$

$$0 \leq \epsilon_1 \leq 1$$

$$0 \leq \epsilon_2 \leq 1$$

$$C_{XZ} = 1 + [(1 - [\epsilon_1(1 - \epsilon_2) + \epsilon_2(1 - \epsilon_1)]) \log_b (1 - [\epsilon_1(1 - \epsilon_2) + \epsilon_2(1 - \epsilon_1)]) + [\epsilon_1(1 - \epsilon_2) + \epsilon_2(1 - \epsilon_1)] \log_b [\epsilon_1(1 - \epsilon_2) + \epsilon_2(1 - \epsilon_1)]]$$



- **Explanation**

The more the error is close to 0.5, the less information can be transmitted.

(symmetry of p & $1 - p$)

If we gain certainty about a high or a low error rate, we remove uncertainty from the channel.

Example: if error rate approach 1, the information can be almost intact when we reverse it.